

Lightweight Model Design for Efficient Bone Suppression Image Transformation


Lee sangjun

Introduction

의료 영상 분석에서 중요한 작업 중 하나인 Bone Suppression, 즉 의료 사진에서 뼈 정보를 억제하는 기술에 대해 다룹니다.


특히 흉부 X-ray에서 미세한 병변, 예를 들어 폐결절이나 종양 검출의 정확도를 높이는 데 필수적입니다.

뼈 구조가 폐 조직을 가리는 경우 병변 탐지가 어려워지기 때문에, 효과적인 Bone Suppression은 임상 현장에서 매우 중요한 역할을 차지합니다.



기존의 Bone Suppression 방식은 필터링, 이미지 분리 등 전통적인 영상 처리 기법이나, Dual Energy Subtraction 과 같은 물리적인 영상 획득법(예: 이중 에너지 촬영)에 많이 의존해 왔습니다.

하지만 이런 방법들은 기계 비용이 높거나 임상 적용이 어렵고, 고품질 결과를 얻기 위해 많은 추가 처리 과정이 필요합니다.



Original Image

Bone Tissue

Soft Tissue


Virtual Dual-Energy Subtraction

Applications of Image-to-Image Translation

의료 영상은 뼈가 제거된 이미지 변환 기술과 : MRI → CT, X-ray → MRI 등 서로 다른 의료 영상 사이 변화 및 변환을 통해 진단 보조 및 데이터 증강에 사용됩니다.


그 외에도 위성 및 원격탐사, 스타일 변환, 로봇공학 및 자율주행시 보행자 검출 향상 기술, 증강현실 (AR) 및 가상현실(VR) 등 다양한 곳에 쓰일 수 있습니다.

Healthcare & Medical Imaging



<https://www.konicaminolta.com/global-en/healthcare/products/healthcare-it/bs/index.html>
<https://www.mdpi.com/2072-4292/16/21/4045>
<https://arxiv.org/pdf/2209.03625>

Satellite & Remote Sensing



Map making and updating: convert satellite images into map images or use them for change detection.

Robotics & Autonomous Driving



Pedestrian detection

Pix2Pix

“Pix2Pix는 "Image-to-Image Translation with Conditional Adversarial Networks" 논문에서 발표한 모델로, 조건부 생성적 적대 신경망(Conditional GAN) 모델에 기반한 Image-to-Image Translation 모델입니다.

Conditional GAN, cGAN은 판별기 D와 생성기 G가 클래스 레이블, 이미지와 같은 추가 정보 y 에 의해 조건화되도록 조건부 모델로 간단히 확장된 버전의 생성 모델입니다.




Image-to-Image Translation with Conditional Adversarial Networks

We investigate conditional adversarial networks as a general-purpose solution to image-to-image translation problems. These networks not only learn the mapping from input image to output image,...

Generator는 입력 이미지를 바탕으로 원하는 출력 이미지를 생성해내는 역할을 합니다.
Discriminator는 생성된 이미지가 진짜인지 가짜인지 판별하는 역할을 하죠.

이 둘은 서로 경쟁하며 학습하는데, Generator는 Discriminator를 속이기 위해 더욱 정교한 이미지를 생성하려 하고, Discriminator는 Generator의 속임수를 간파하기 위해 더욱 날카로운 판별력을 기르게 됩니다.


Discriminator는 PatchGAN 이라는 독특한 구조를 채택하고 있습니다.

전체 이미지를 한 번에 판별하는 것이 아니라, 이미지를 여러 개의 작은 패치로 나누어 각 패치가 진짜인지 가짜인지 판별합니다.


이러한 방식은 이미지의 지역(local)적인 특징 을 더욱 세밀하게 분석할 수 있도록 도와줍니다.

- 예를 들어 오른쪽 아래 그림처럼 입력 데이터 : 그래픽 이미지를 $\rightarrow$ 사진 형태의 이미지로 변환하고 싶을 때, 조건이 없는 GAN 모델과 달리 generator, discriminator 둘 다 입력 그래픽 x 를 관찰합니다.
- 생성기는 미러링된 레이어 간에 스킵 연결이 있는 인코더-디코더인 U-Net을 사용하여 주어진 조건의 이미지로 만들어내려 노력하게 됩니다.
- 판별기는 컨벌루션 기반 PatchGAN classifier를 사용하여 이미지 패치 $N \times N$ 규모의 구조에 각 패치가 실제인지 가짜인지 분류하려고 합니다.


하지만 Pix2Pix 모델들은 높은 성능을 위해 많은 메모리와 연산량을 요구합니다.
특히 대용량 이미지를 다루거나 서버 환경이 제한적인 경우, 모델 적용에 많은 어려움이 있습니다.
이러한 문제를 해결하기 위해 경량화(Lightweight) 모델이 요구되고 있습니다.




Discriminator uses a convolutional PatchGAN classifier, which only penalizes structure at the scale of image patches $N \times N$, so it tries to classify if each patch is real or fake.



Generator : Lightweight U-Net






Discriminator : PatchGAN



Dataset

2048*2048 의 CXR 이미지.



Experiment settings :

첫 번째 모델 : 큰 사이즈의 패치로 나누기

두 번째 모델 : 작은 사이즈부터 상대적으로 큰 사이즈(256~1024)의 패치로 나눠 세분화된 학습

세 번째 모델 : 상대적으로 작은 패치로 나누기

네 번째 모델 : Loss function 에 perceptual loss function 추가

Experiments : Train data

Original 007.png



Output7.png




Original BS 003.png



Output3.png




Original 41.png




Output_41.png



Original 002.png




Output2.png




Experiments : Data generalization

Original 002.png



Output2.png



Original d 14.png



Output_14.png



Original 161510.png



Output_161510.png



PSNR

$$\begin{aligned} PSNR &= 10 \cdot \log_{10} \left(\frac{MAX_I^2}{MSE} \right) \\ &= 20 \cdot \log_{10} \left(\frac{MAX_I}{\sqrt{MSE}} \right) \\ &= 20 \cdot \log_{10}(MAX_I) - 10 \cdot \log_{10}(MSE) \end{aligned}$$

- MSE (평균 제곱 오차)
- MAX_I: 픽셀의 최대값 (8비트 이미지의 경우 255)
- PSNR 값이 높을수록 두 이미지가 유사하다는 의미입니다.
- 30dB 이상이면 두 이미지의 차이를 눈으로 구분하기 어렵다고 평가됩니다.

SSIM

$$SSIM(x, y) = \frac{(2\mu_x\mu_y + c_1)(2\sigma_{xy} + c_2)}{(\mu_x^2 + \mu_y^2 + c_1)(\sigma_x^2 + \sigma_y^2 + c_2)}$$

- μ_x, μ_y : 각 이미지의 평균값
- σ_x, σ_y : 각 이미지의 표준편차
- σ_{xy} : 두 이미지 간의 공분산
- SSIM 값은 0~1 사이의 값을 가집니다.
- 1에 가까울수록 두 이미지가 유사합니다.

Experiment Result:

	Model 1	Model 2	Model 3	Model 4
SSIM	0.9807	0.9835	0.979	0.9763
PSNR	40.6908	40.9663	39.985	38.0264

Discussion : Improve Generalization Performance

일반적인 데이터에서도 학습된 데이터만큼의 Bone suppression 성능을 유지하는 것이 추가 연구 작업입니다.

실제 임상 적용을 위해서는 더 다양하고 대규모의 데이터셋에서의 검증이 필요합니다.

향후에는 일반화 성능 향상을 위한 다양한 method(CycleGAN을 활용한 Unpaired Learning이나 Transformer 기반 모델 도입 가능성), 그리고 세분화(Segmentation), 질환 탐지와와의 추가 작업 연계 방안도 연구해볼 수 있습니다.”

Conclusion

“Bone Suppression은 흉부 영상의 판독 정확도를 높이는 핵심 기술입니다.

Pix2Pix 등 최신 Image-to-Image Translation 모델의 적용은 의료 AI의 실제 임상 활용 가능성을 한 단계 끌어올릴 수 있습니다.

QnA